

UNIVERSIDAD TECNOLÓGICA DE PEREIRA · MAESTRÍA EN INGENIERÍA EN SISTEMAS Y
COMPUTACIÓN

Estabilidad de Métodos de Explicabilidad (XAI) en Graph Neural Networks para la Detección de Lavado de Dinero bajo Desbalance Extremo

Alejandro Gómez Huertas · Juan Diego Garzón Ovalle

Director: Ph.D. Cristian Rosero Arias

Pereira, Colombia · 2026

Contenido

- 1 **Problema y motivación** — detección de lavado y la opacidad de las GNN
- 2 **Pregunta y objetivos**
- 3 **Metodología: dos ejes** — Elliptic real + grafo sintético con *ground-truth*
- 4 **Resultados** — estabilidad, plausibilidad, fidelidad y sus relaciones
- 5 **Conclusiones** — aportes, límites y trabajo futuro




1 . Problema y motivación


El problema: detectar lavado sin caja negra

- El lavado mueve el **2–5 % del PIB mundial**; los sistemas por reglas generan **95–98 % de falsos positivos**.
- Las **GNN** modelan las transacciones como grafo y superan a lo tabular.
- **Pero son cajas negras**: en un entorno regulado, cada alerta debe ser justificable y reproducible.

Enfoque tradicional basado en reglas



Enfoque relacional basado en grafos



Pregunta de investigación y objetivos

Pregunta

¿Cómo se comporta la **estabilidad** de los métodos XAI sobre GNNs para AML bajo desbalance, y qué combinación de arquitectura, explicador y balanceo optimiza la interpretación robusta y auditable?

- 01 Degradación de la estabilidad con el desbalance.
- 02 Resiliencia de GCN, GraphSAGE, GAT, TAGCN.
- 03 Impacto de las estrategias de balanceo.
- 04 Matriz de recomendación.

La brecha en el estado del arte

Lo que ya se sabía

- Las GNN superan a lo tabular (Weber 2019).
- TAGCN + SHAP con alto rendimiento (He 2026).
- Predicción y explicabilidad, por separado.

Lo que faltaba

- La **estabilidad** de las explicaciones sobre grafos AML no se había evaluado sistemáticamente.
- Elliptic no tiene *ground-truth* de tipología $\Rightarrow$ la plausibilidad no era medible.



2 · Marco conceptual

Marco: redes de grafos y explicabilidad

4 arquitecturas GNN

- **GCN** — convolución espectral (1 salto)
- **GraphSAGE** — muestreo + agregación inductiva
- **GAT** — atención multi-cabeza
- **TAGCN** — filtros polinómicos de orden K

3 explicadores XAI (post-hoc)

- **GNNExplainer** — máscara por instancia
- **PGExplainer** — red generativa entrenada
- **GNNShap** — valores de Shapley por muestreo

Tres propiedades que no son lo mismo

Estabilidad

¿La explicación se reproduce entre semillas y perturbaciones?

Plausibilidad

¿Señala el patrón real de lavado (*ground-truth*)?

Fidelidad

¿Refleja de verdad la decisión interna del modelo?

Tesis central: *las tres son empíricamente independientes.*



3 · Metodología

Metodología: un diseño de dos ejes

Eje 1 · Elíptico (real)

- Validez **externa**: transacciones reales.
- Sin *ground-truth* $\Rightarrow$ solo estabilidad.
- Campo receptivo minúsculo (~ 2 nodos).

Eje 2 · Sintético (propio)

- Validez **interna**: *ground-truth* por nodo y arista.
- Permite medir plausibilidad y fidelidad.
- 4 tipologías estándar; 3 realizaciones.

Diseño factorial

4 arquitecturas × 3 explicadores × 3 balanceos × 5 escenarios


= 60 configuraciones por eje × 3 explicadores para el estudio de estabilidad

Protocolo de robustez

Estabilidad: 5 réplicas estocásticas por explicación. Inferencia (eje sintético): 3 semillas de modelo × 3 grafos, con Kruskal-Wallis, Wilcoxon e IC bootstrap.


Eje 1 — Elliptic Bitcoin Dataset

- 203.769 nodos · 234.355 aristas · 166 features · 49 pasos.
- Ilícitas $\sim 2,2\%$ (razón $\sim 1:9$ en el subconjunto etiquetado).
- Split temporal causal (train 1–34 / val 35–42 / test 43–49).
- Campo receptivo mediana ~ 2 nodos $\Rightarrow$ solo el Spearman discrimina.



Eje 2 — grafo sintético con ground-truth

- **¿Por qué?** medir plausibilidad exige saber cuál subgrafo es el patrón — Elliptic no lo da.
- 4 tipologías: *structuring*, *layering*, *fan-in*, *fan-out*.
- Aristas distractoras + firma atenuada $\Rightarrow$ la métrica discrimina.
- *Ground-truth* ciego al explicador; 3 realizaciones.



Métricas y protocolo estadístico

- **Estabilidad** — correlación de Spearman entre rankings de features (primaria).
- **Plausibilidad** — coincidencia con el *ground-truth* de la tipología.
- **Fidelidad** — caída de la predicción al retirar lo importante.
- **Rendimiento** — PR-AUC como métrica primaria (el F1 en umbral es degenerado bajo desbalance).

Estadística: Kruskal-Wallis, Wilcoxon, intervalos de confianza *bootstrap*.



4 · Resultados

Contribución: dos artefactos de evaluación

1 · Fallo de memoria silencioso

Cálculo sobre el grafo completo $\Rightarrow$ 13 configuraciones de GAT fallaban en silencio $\Rightarrow$ favorecía a GAT.

2 · Truncamiento del Spearman

La métrica descartaba features fuera del umbral $\Rightarrow$ rankings mutilados $\Rightarrow$ favorecía a GraphSAGE.


Cada uno bastaba para una conclusión comparativa falsa. La estabilidad depende del protocolo de medición.

Además: dos *bugs* reportables en el PGExplainer de PyG 2.7.

Resultado 1 — la estabilidad separa dos grupos, no cuatro puestos

■ GAT	$0,782 \pm 0,013$
■ GCN	$0,758 \pm 0,025$
— diferencia significativa —	
■ GraphSAGE	$0,735 \pm 0,022$
■ TAGCN	$0,676 \pm 0,077$

Media de **3 semillas** de modelo (180 modelos).
Significativo **entre** grupos, **no dentro**: GAT vs GCN $p = 0,17$; GraphSAGE vs TAGCN $p = 0,10$.



Robustez: qué sostiene esa partición

Contraste	Estadístico	p
Global (4 arquitecturas)	Kruskal-Wallis	$2,8 \times 10^{-5}$
Grupo alto vs bajo	Mann-Whitney	$1,4 \times 10^{-6}$
Dentro del grupo alto	Kruskal-Wallis	0,19
Dentro del grupo bajo	Kruskal-Wallis	0,08

- Tamaño de efecto $\eta^2 = 0,125$.
- IC95 % bootstrap: se solapan **dentro** de cada grupo, apenas se tocan **entre** grupos.

Reproducibilidad, en sentido preciso

Reentrenamos la matriz completa desde cero.
Los **pesos no** se reproducen bit a bit (los *scatter* en GPU acumulan con sumas atómicas).

Las **conclusiones sí**: 25/60 sobre el filtro de calidad frente a 23/60, y la **misma partición**.

Distinguir ambas cosas es, en sí mismo, una contribución metodológica.

Resultado 1b — concordancia entre regímenes


- La “inversión por densidad” era un **artefacto** de la métrica.
- Corregida, Elliptic (disperso) **concuerta** con el sintético (denso).
- Y la coincidencia no es solo de orden: el eje sintético separa **los mismos dos grupos**, medido sobre datos y *pipeline* independientes.

Correlación de rangos entre regímenes

−0,20 → +0,80


métrica con bug → métrica corregida

Sintético: GCN 0,97 y GAT 0,96 frente a
GraphSAGE 0,89 y TAGCN 0,89




Resultado 2 — disociación plausibilidad / fidelidad

- **PGExplainer** recupera mejor el patrón: plausibilidad 0,80 vs 0,50 (Wilcoxon $p \approx 2,6 \times 10^{-35}$)...
- ... pero **colapsa en fidelidad**: 0,11 vs 0,56 de GNNExplainer.
- *El explicador más “plausible” no es el más fiel.*



Resultado 3 — puente nulo y balanceo irrelevante

- Hipótesis central (estable $\Rightarrow$ plausible): **refutada**.
- Correlación estabilidad–plausibilidad $r = -0,01$ (IC 95 % incluye el cero).
- El balanceo es prácticamente **irrelevante** ($\eta^2 < 0,02$).
- *Un no-resultado, reportado con honestidad.*



Rendimiento y colapso validación → test

PR-AUC

0,367

validación

→ test **0,017**

ROC-AUC

0,884

validación

→ test **0,653**

Precision@50

0,657

validación

→ test **0,020**

El **ROC-AUC** es **engañoso** bajo desbalance ⇒ PR-AUC y precision@k como primarias.
La estabilidad se estudia sobre verdaderos positivos de **validación** (encuadre declarado).



5 · Conclusiones

Matriz de recomendación

Objetivo operativo	Configuración
Auditabilidad / estabilidad	grupo alto: GAT o GCN
Recuperar el patrón (plausibilidad)	PGExplainer
Fidelidad al modelo	GNNExplainer
Estabilidad interna del método	GNNShap

La recomendación de arquitectura es **de grupo**, no de una arquitectura concreta: dentro del grupo alto la evidencia no distingue, así que la elección puede atender a coste o disponibilidad.

Contribuciones y limitaciones

Contribuciones

- Tres dimensiones independientes.
- Corrección de dos artefactos + dos *bugs* de PGExplainer.
- Generador sintético con *ground-truth* por arista.
- Reproducibilidad de **pesos** frente a la de **conclusiones**.
- Matriz de recomendación por objetivo.

Limitaciones (declaradas)

- La inferencia fuerte proviene del eje sintético.
- El clasificador colapsa en test (*shift* temporal).
- Un solo *dataset* real, anonimizado.
- Con 3 semillas se sostiene el **grupo**, no el orden fino dentro de él.

Conclusiones

- Estabilidad, plausibilidad y fidelidad: el mejor explicador depende del objetivo.
- Con la medición correcta, datos reales y sintéticos cuentan una historia coherente (LIFT/GCN stability).
- La estabilidad de una explicación depende del protocolo de evaluación, no solo del método.

Trabajo futuro: Elliptic2, AMLSim, GNNs temporales, GraphSMOTE.

Gracias · Preguntas

Alejandro Gómez Huertas · Juan Diego Garzón Ovalle

Respaldo · solo si se pregunta

Respaldo · el segundo artefacto, en detalle

La métrica dimensionaba el vector de rangos por top_k en vez de por el número real de *features*.

Con top_k= 20 sobre **166 features**, toda *feature* con índice ≥ 20 se descartaba: sobrevivían 2 o 3 de las 20 y el resto quedaba empatado en cero.

El truncamiento **no penaliza por igual**: castiga más a las arquitecturas cuya importancia se reparte sobre muchas *features*.

Por eso deprimía a GAT (+0,24 al corregir) y a TAGCN (+0,28) mucho más que a GraphSAGE (+0,10), y fabricaba un liderazgo falso.

Los dos artefactos, juntos

1. **Memoria**: 13 configs de GAT fallaban por OOM silencioso; su media se calculaba solo sobre las que terminaban. *Favorecía a GAT.*

2. **Métrica**: el truncamiento anterior. *Favorecía a GraphSAGE.*

Cada uno **por separado** bastaba para una conclusión comparativa falsa.

Respaldo · estabilidad por semilla de modelo

Arquitectura	s42	s43	s44	Media	IC95 %
GAT	0,766	0,789	0,790	0,782	[0,758; 0,805]
GCN	0,783	0,733	0,757	0,758	[0,724; 0,787]
GraphSAGE	0,756	0,713	0,738	0,735	[0,710; 0,756]
TAGCN	0,586	0,693	0,736	0,676	[0,632; 0,717]

GAT y GCN se permutan entre semillas: por eso no nombramos un ganador único.
TAGCN tiene la mayor dispersión (dt 0,077, el triple que las demás): su lugar en el grupo bajo es firme, su valor central admite margen.

Respaldo · detalle estadístico de la partición

Wilcoxon pareado	Elliptic	Sintético
GAT vs GCN <i>(dentro del grupo alto)</i>	0,165	0,0013
GraphSAGE vs TAGCN <i>(dentro del grupo bajo)</i>	0,096	0,519
GAT vs GraphSAGE	0,0033	$< 10^{-4}$
GAT vs TAGCN	$< 10^{-4}$	$< 10^{-4}$
GCN vs GraphSAGE	0,047	$< 10^{-4}$
GCN vs TAGCN	0,0067	$< 10^{-4}$

La única diferencia intragrupo significativa es GCN sobre GAT en el eje sintético, por un margen de **0,006** sin relevancia práctica, detectable solo por el mayor n de ese eje.

Respaldo · por qué PR-AUC y no ROC-AUC

Métrica de ordenamiento	Validación	Test
ROC-AUC	0,884	0,653
PR-AUC	0,367	0,017
Precisión en los primeros 50	0,657	0,020
Precisión en los primeros 100	0,640	0,022

El ROC-AUC de 0,884 sugeriría un clasificador casi excelente. El PR-AUC de 0,367 sobre los mismos modelos revela la dificultad real: bajo desbalance extremo, el eje de falsos positivos queda dominado por la clase mayoritaria y permanece bajo aunque el modelo no distinga la clase rara.

Respaldo · cómo se construyó el grafo sintético

Decisiones que endurecen la prueba

- **Simetrización** de aristas: sin ella el campo receptivo cae a ~ 2 nodos y la plausibilidad de subgrafo no es medible.
- **Aristas distractoras** ($n = 3$ por nodo de patrón): sin ellas cualquier selección *top-k* acertaría.
- **Firma de *features* atenuada** de $+4$ a $+1,5$: evita que la tarea se resuelva sola.

El *ground-truth* se fija en la construcción, **antes** de correr ningún explicador.

Escala y replicación

- ≈ 9.500 nodos, ≈ 1.530 ilícitos, ≈ 31.000 aristas.
- 4 tipologías canónicas: *structuring*, *layering*, *fan-in*, *fan-out*.
- Grafo g_0 : factorial completo $\times$ 3 semillas de modelo (540 filas).
- Grafos g_1 y g_2 : corte de verificación, escenarios 1:1 y nativo (144 filas).

El contraste principal se calcula sobre la unión de los tres grafos.