

UNIVERSIDAD TECNOLÓGICA DE PEREIRA · MAESTRÍA EN INGENIERÍA EN SISTEMAS Y
COMPUTACIÓN

Estabilidad de Métodos de Explicabilidad (XAI) en Graph Neural Networks para la Detección de Lavado de Dinero bajo Desbalance Extremo

Alejandro Gómez Huertas · **Juan Diego Garzón Ovalle**

Director: Ph.D. Cristian Rosero Arias

Pereira, Colombia · 2026

Contenido

- 1 **Problema y motivación** — detección de lavado y la opacidad de las GNN
- 2 **Pregunta y objetivos**
- 3 **Metodología: dos ejes** — Elliptic real + grafo sintético con *ground-truth*
- 4 **Resultados** — estabilidad, plausibilidad, fidelidad y sus relaciones
- 5 **Conclusiones** — aportes, límites y trabajo futuro




1 . Problema y motivación


El problema: detectar lavado sin caja negra

- El lavado mueve el **2–5 % del PIB mundial**; los sistemas por reglas generan **95–98 % de falsos positivos**.
- Las **GNN** modelan las transacciones como grafo y superan a lo tabular.
- **Pero son cajas negras**: en un entorno regulado, cada alerta debe ser justificable y reproducible.

Enfoque tradicional basado en reglas



Enfoque relacional basado en grafos



Pregunta de investigación y objetivos

Pregunta

¿Cómo se comporta la **estabilidad** de los métodos XAI sobre GNNs para AML bajo desbalance, y qué combinación de arquitectura, explicador y balanceo optimiza la interpretación robusta y auditable?

- 01 Degradación de la estabilidad con el desbalance.
- 02 Resiliencia de GCN, GraphSAGE, GAT, TAGCN.
- 03 Impacto de las estrategias de balanceo.
- 04 Matriz de recomendación.

La brecha en el estado del arte

Lo que ya se sabía

- Las GNN superan a lo tabular (Weber 2019).
- TAGCN + SHAP con alto rendimiento (He 2026).
- Predicción y explicabilidad, por separado.

Lo que faltaba

- La **estabilidad** de las explicaciones sobre grafos AML no se había evaluado sistemáticamente.
- Elliptic no tiene *ground-truth* de tipología $\Rightarrow$ la plausibilidad no era medible.



2 · Marco conceptual

Marco: redes de grafos y explicabilidad

4 arquitecturas GNN

- **GCN** — convolución espectral (1 salto)
- **GraphSAGE** — muestreo + agregación inductiva
- **GAT** — atención multi-cabeza
- **TAGCN** — filtros polinómicos de orden K

3 explicadores XAI (post-hoc)

- **GNNExplainer** — máscara por instancia
- **PGExplainer** — red generativa entrenada
- **GNNShap** — valores de Shapley por muestreo

Tres propiedades que no son lo mismo

Estabilidad

¿La explicación se reproduce entre semillas y perturbaciones?

Plausibilidad

¿Señala el patrón real de lavado (*ground-truth*)?

Fidelidad


¿Refleja de verdad la decisión interna del modelo?

Tesis central: *las tres son empíricamente independientes.*



3 · Metodología

Qué produce, en concreto, un explicador



● nodo a explicar — aristas relevantes

Ante una transacción marcada como ilícita, el explicador devuelve dos cosas:

1. Una **máscara de aristas**: qué conexiones del vecindario sostienen la predicción.
2. Un **ranking de *features***: qué atributos del nodo pesaron más, de los 166 disponibles.

Sobre eso se definen las tres preguntas:

Estabilidad: ¿sale lo mismo al repetir?

Plausibilidad: ¿coincide con el patrón real?

Fidelidad: ¿es lo que el modelo usó?

En Elliptic el vecindario tiene una mediana de ~ 2 nodos, así que ahí solo el ranking de *features* discrimina.

Metodología: un diseño de dos ejes

Eje 1 · Elíptico (real)

- Validez **externa**: transacciones reales.
- Sin *ground-truth* $\Rightarrow$ solo estabilidad.
- Campo receptivo minúsculo (~ 2 nodos).

Eje 2 · Sintético (propio)

- Validez **interna**: *ground-truth* por nodo y arista.
- Permite medir plausibilidad y fidelidad.
- 4 tipologías estándar; 3 realizaciones.

Diseño factorial

4 arquitecturas × 3 explicadores × 3 balanceos × 5 escenarios


= 60 configuraciones por eje × 3 explicadores para el estudio de estabilidad

Protocolo de robustez

Estabilidad: 5 réplicas estocásticas por explicación. Inferencia (eje sintético): 3 semillas de modelo × 3 grafos, con Kruskal-Wallis, Wilcoxon e IC bootstrap.


Eje 1 — Elliptic Bitcoin Dataset

- 203.769 nodos · 234.355 aristas · 166 features · 49 pasos.
- Ilícitas $\sim 2,2\%$ (razón $\sim 1:9$ en el subconjunto etiquetado).
- Split temporal causal (train 1–34 / val 35–42 / test 43–49).
- Campo receptivo mediana ~ 2 nodos $\Rightarrow$ solo el Spearman discrimina.



Eje 2 — grafo sintético con ground-truth

- **¿Por qué?** medir plausibilidad exige saber cuál subgrafo es el patrón — Elliptic no lo da.
- 4 tipologías: *structuring*, *layering*, *fan-in*, *fan-out*.
- Aristas distractoras + firma atenuada $\Rightarrow$ la métrica discrimina.
- *Ground-truth* ciego al explicador; 3 realizaciones.



Cómo se construyó el grafo sintético

Decisiones que endurecen la prueba

- **Simetrización** de aristas: sin ella el campo receptivo cae a ~ 2 nodos y la plausibilidad de subgrafo no es medible.
- **Aristas distractoras** ($n = 3$ por nodo de patrón): sin ellas cualquier selección *top-k* acertaría.
- **Firma de *features* atenuada** de $+4$ a $+1,5$: evita que la tarea se resuelva sola.

El *ground-truth* se fija en la construcción, **antes** de correr ningún explicador.

Escala y replicación

- ≈ 9.500 nodos, ≈ 1.530 ilícitos, ≈ 31.000 aristas.
- 4 tipologías canónicas: *structuring*, *layering*, *fan-in*, *fan-out*.
- Grafo g_0 : factorial completo $\times 3$ semillas de modelo (540 filas).
- Grafos g_1 y g_2 : corte de verificación, escenarios 1:1 y nativo (144 filas).

El contraste principal se calcula sobre la unión de los tres grafos.

Métricas y protocolo estadístico

- **Estabilidad** — correlación de Spearman entre rankings de features (primaria).
- **Plausibilidad** — coincidencia con el *ground-truth* de la tipología.
- **Fidelidad** — caída de la predicción al retirar lo importante.
- **Rendimiento** — PR-AUC como métrica primaria (el F1 en umbral es degenerado bajo desbalance).

Estadística: Kruskal-Wallis, Wilcoxon, intervalos de confianza *bootstrap*.



4 · Resultados

Contribución: dos artefactos de evaluación

1 · Fallo de memoria silencioso

Cálculo sobre el grafo completo $\Rightarrow$ 13 configuraciones de GAT fallaban en silencio $\Rightarrow$ favorecía a GAT.

2 · Truncamiento del Spearman

La métrica descartaba features fuera del umbral $\Rightarrow$ rankings mutilados $\Rightarrow$ favorecía a GraphSAGE.

Cada uno bastaba para una conclusión comparativa falsa. La estabilidad depende del protocolo de medición.

Además: dos *bugs* reportables en el PGExplainer de PyG 2.7.

El segundo artefacto: el truncamiento de la métrica

La métrica dimensionaba el vector de rangos por `top_k` en vez de por el número real de *features*.

Con `top_k= 20` sobre **166 features**, toda *feature* con índice ≥ 20 se descartaba: sobrevivían 2 o 3 de las 20 y el resto quedaba empatado en cero.

El truncamiento **no penaliza por igual**: castiga más a las arquitecturas cuya importancia se reparte sobre muchas *features*.

Por eso deprimía a GAT (+0,24 al corregir) y a TAGCN (+0,28) mucho más que a GraphSAGE (+0,10), y fabricaba un liderazgo falso.

Los dos artefactos, juntos

1. **Memoria**: 13 configs de GAT fallaban por OOM silencioso; su media se calculaba solo sobre las que terminaban. *Favorecía a GAT.*


2. **Métrica**: el truncamiento anterior. *Favorecía a GraphSAGE.*

Cada uno **por separado** bastaba para una conclusión comparativa falsa.

Resultado 1 — la estabilidad separa dos grupos, no cuatro puestos

■ GAT	$0,782 \pm 0,013$
■ GCN	$0,758 \pm 0,025$
— diferencia significativa —	
■ GraphSAGE	$0,735 \pm 0,022$
■ TAGCN	$0,672 \pm 0,077$

Media de **3 semillas** de modelo (180 modelos).
Significativo **entre** grupos, **no dentro**: GAT vs GCN $p = 0,17$; GraphSAGE vs TAGCN $p = 0,10$.



Robustez: qué sostiene esa partición

Contraste	Estadístico	p
Global (4 arquitecturas)	Kruskal-Wallis	$2,8 \times 10^{-5}$
Grupo alto vs bajo	Mann-Whitney	$1,4 \times 10^{-6}$
Dentro del grupo alto	Kruskal-Wallis	0,19
Dentro del grupo bajo	Kruskal-Wallis	0,08

- Tamaño de efecto $\epsilon^2 = 0,125$.
- IC95 % bootstrap: se solapan **dentro** de cada grupo, apenas se tocan **entre** grupos.

Reproducibilidad, en sentido preciso

Reentrenamos la matriz completa desde cero.
Los **pesos no** se reproducen bit a bit (los *scatter* en GPU acumulan con sumas atómicas).

Las **conclusiones sí**: 25/60 sobre el filtro de calidad frente a 23/60, y la **misma partición**.

Distinguir ambas cosas es, en sí mismo, una contribución metodológica.

Resultado 1b — concordancia entre regímenes


- La “inversión por densidad” era un **artefacto** de la métrica.
- Corregida, Elliptic (disperso) **concuerta** con el sintético (denso).
- Y la coincidencia no es solo de orden: el eje sintético separa **los mismos dos grupos**, medido sobre datos y *pipeline* independientes.

Correlación de rangos entre regímenes

−0,20 → +0,80


métrica con bug → métrica corregida

Sintético: GCN 0,97 y GAT 0,96 frente a
GraphSAGE 0,89 y TAGCN 0,89



Resultado 2 — disociación plausibilidad / fidelidad


- **PGExplainer** recupera mejor el patrón: plausibilidad 0,80 vs 0,50 (Wilcoxon $p \approx 2,6 \times 10^{-35}$)...
- ... pero **colapsa en fidelidad**: 0,11 vs 0,56 de GNNExplainer.
- *El explicador más “plausible” no es el más fiel.*



Resultado 3 — el puente que no existe


- Nuestra hipótesis central: una explicación más estable señalaría mejor el patrón real.
- El dato dice que **no**. Correlación estabilidad-plausibilidad $r = -0,01$, con IC 95 % de $-0,038$ a $+0,011$.
- El intervalo **incluye el cero**: no hay relación, ni positiva ni negativa.

Es un no-resultado, y lo reportamos precisamente porque contradice lo que esperábamos.



Resultado 4 — el desbalance no gobierna la estabilidad

- Esperábamos degradación al agravarse el desbalance. El perfil es **plano**.
- Entre escenarios la estabilidad media apenas se mueve, de 0,709 en el nativo a 0,741 en 1:100: una amplitud total de **tres centésimas**.
- Sin punto de quiebre, sin pico en 1:50, sin paradoja del escenario nativo.
- El **balanceo** tampoco pesa: $\eta^2 < 0,02$ en las tres dimensiones.



Implicación práctica: el balanceo puede elegirse por **rendimiento**, sin temer que degrade la interpretabilidad.

Rendimiento y colapso validación → test

PR-AUC

0,367

validación

→ test **0,017**

ROC-AUC

0,884

validación

→ test **0,653**

Precision@50

0,657

validación

→ test **0,020**

El **ROC-AUC** es **engañoso** bajo desbalance ⇒ PR-AUC y precision@k como primarias.
La estabilidad se estudia sobre verdaderos positivos de **validación** (encuadre declarado).

Rigor métrico: por qué PR-AUC y no ROC-AUC

Métrica de ordenamiento	Validación	Test
ROC-AUC	0,884	0,653
PR-AUC	0,367	0,017
Precisión en los primeros 50	0,657	0,020
Precisión en los primeros 100	0,640	0,022

El ROC-AUC de 0,884 sugeriría un clasificador casi excelente. El PR-AUC de 0,367 sobre los mismos modelos revela la dificultad real: bajo desbalance extremo, el eje de falsos positivos queda dominado por la clase mayoritaria y permanece bajo aunque el modelo no distinga la clase rara.

Las tres hipótesis, y qué pasó con cada una

Lo que predijimos	Veredicto	La evidencia
H1. La estabilidad se degradaría al agravarse el desbalance.	Refutada	Perfil plano: amplitud total de 0,03 entre escenarios (mín. 0,709 nativo, máx. 0,741 en 1:100).
H2. TAGCN sería la más estable, por su alcance multi-hop.	Refutada	TAGCN queda en el grupo bajo en las 3 semillas.
H3. Un explicador más estable señalaría mejor el patrón.	Refutada	Puente nulo: $r = -0,01$, IC incluye el cero.

Las tres se cayeron. **Ninguna se ocultó.**

Comprometerse con predicciones falsables antes de ver los datos es lo que permite que refutarlas sea un resultado, y no un fracaso.



5 · Conclusiones

Los cuatro objetivos, respondidos

Objetivo	Respuesta
O1. Impacto del desbalance sobre la robustez explicativa	No es el factor dominante. El perfil es plano y el balanceo tiene efecto despreciable. La palanca real es el explicador .
O2. Resiliencia comparada de las 4 arquitecturas	No hay cuatro posiciones, hay dos grupos : alto (GAT, GCN) y bajo (GraphSAGE, TAGCN). La partición se replica en ambos regímenes de densidad.
O3. Impacto de las estrategias de balanceo	Despreciable sobre las tres dimensiones ($\eta^2 < 0,02$). Puede elegirse por rendimiento.
O4. Matriz de recomendación técnica	No existe una tríada óptima única. La recomendación es condicional al propósito de la auditoría.

Matriz de recomendación

Objetivo operativo	Configuración
Auditabilidad / estabilidad	grupo alto: GAT o GCN
Recuperar el patrón (plausibilidad)	PGExplainer
Fidelidad al modelo	GNNExplainer
Estabilidad interna del método	GNNShap

La recomendación de arquitectura es **de grupo**, no de una arquitectura concreta: dentro del grupo alto la evidencia no distingue, así que la elección puede atender a coste o disponibilidad.

Contribuciones y limitaciones

Contribuciones

- Tres dimensiones independientes.
- Corrección de dos artefactos + dos *bugs* de PGExplainer.
- Generador sintético con *ground-truth* por arista.
- Reproducibilidad de **pesos** frente a la de **conclusiones**.
- Matriz de recomendación por objetivo.

Limitaciones (declaradas)

- La inferencia fuerte proviene del eje sintético.
- El clasificador colapsa en test (*shift* temporal).
- Un solo *dataset* real, anonimizado.
- Con 3 semillas se sostiene el **grupo**, no el orden fino dentro de él.

Conclusiones

- Estabilidad, plausibilidad y fidelidad: el mejor explicador depende del objetivo.
- Con la medición correcta, datos reales y sintéticos cuentan una historia coherente (LIFT, GLEU, etc.).
- La estabilidad de una explicación depende del protocolo de evaluación, no solo del método.

Trabajo futuro: Elliptic2, AMLSim, GNNs temporales, GraphSMOTE.

Gracias · Preguntas

Alejandro Gómez Huertas · Juan Diego Garzón Ovalle

Respaldo · solo si se pregunta

Respaldo · estabilidad por semilla de modelo

Arquitectura	s42	s43	s44	Media	IC95 %
GAT	0,766	0,789	0,790	0,782	[0,758; 0,805]
GCN	0,783	0,733	0,757	0,758	[0,724; 0,787]
GraphSAGE	0,756	0,713	0,738	0,735	[0,710; 0,756]
TAGCN	0,586	0,693	0,736	0,672	[0,632; 0,717]

GAT y GCN se permutan entre semillas: por eso no nombramos un ganador único.
TAGCN tiene la mayor dispersión (dt 0,077, el triple que las demás): su lugar en el grupo bajo es firme, su valor central admite margen.

Respaldo · detalle estadístico de la partición

Wilcoxon pareado	Elliptic	Sintético
GAT vs GCN <i>(dentro del grupo alto)</i>	0,165	0,0013
GraphSAGE vs TAGCN <i>(dentro del grupo bajo)</i>	0,096	0,519
GAT vs GraphSAGE	0,0033	$< 10^{-4}$
GAT vs TAGCN	$< 10^{-4}$	$< 10^{-4}$
GCN vs GraphSAGE	0,047	$< 10^{-4}$
GCN vs TAGCN	0,0067	$< 10^{-4}$

La única diferencia intragrupo significativa es GCN sobre GAT en el eje sintético, por un margen de **0,006** sin relevancia práctica, detectable solo por el mayor n de ese eje.