

Estabilidad de Métodos de Explicabilidad (XAI) en GNNs

Detección de Lavado de Dinero bajo Desbalance Extremo

Alejandro Gómez Huertas Juan Diego Garzón Ovalle

Trabajo de grado para optar al título de Magíster · Pereira, Colombia · 2026

UNIVERSIDAD TECNOLÓGICA DE PEREIRA

Facultad de Ingenierías · Maestría en Ingeniería en Sistemas y Computación

Director: Ph.D. Cristian Rosero Arias

Contenido de la sustentación

1 Problema y motivación

detección de lavado y la opacidad de las GNN

2 Marco conceptual

arquitecturas, explicadores y las tres propiedades

3 Metodología: dos ejes

Elliptic real + grafo sintético con *ground-truth*

4 Resultados

estabilidad, plausibilidad, fidelidad

5 Conclusiones

aportes, límites y trabajo futuro

Presentación a dos voces

Alejandro: contexto y metodología.
33–36 min.

Juan Diego: resultados y cierre.

Duración objetivo:

Problema y motivación

El problema: detectar lavado sin caja negra

- El lavado mueve el **2–5 % del PIB mundial**; los sistemas por reglas generan **95–98 % de falsos positivos**.
- Las **GNN** modelan las transacciones como grafo y superan a lo tabular.
- **Pero son cajas negras**: en un entorno regulado, cada alerta debe ser justificable y reproducible.

Cifras: informes UNODC y GAFI/FATF (ver Cap. 2 del manuscrito).




Figura 1. Enfoques de detección de lavado: reglas frente a modelos de grafos. *Fuente: elaboración propia.*

Pregunta de investigación y objetivos

Pregunta

¿Cómo se comporta la **estabilidad** de los métodos XAI sobre GNNs para AML bajo desbalance, y qué combinación de arquitectura, explicador y balanceo optimiza la interpretación robusta y auditable?

O1 Degradación de la estabilidad con el desbalance.

O2 Resiliencia de GCN, GraphSAGE, GAT, TAGCN.

O3 Impacto de las estrategias de balanceo.

O4 Matriz de recomendación técnica.

La brecha en el estado del arte

Lo que ya se sabía

- Las GNN superan a lo tabular (Weber et al., 2019).
- TAGCN + SHAP con alto rendimiento (He et al., 2026).
- Predicción y explicabilidad, por separado.

Lo que faltaba

- La **estabilidad** de las explicaciones sobre grafos AML no se había evaluado sistemáticamente.
- Elliptic no tiene *ground-truth* de tipología: la plausibilidad no era medible.

Marco conceptual

4 arquitecturas GNN

- **GCN**: convolución espectral (1 salto)
- **GraphSAGE**: muestreo + agregación inductiva
- **GAT**: atención multi-cabeza
- **TAGCN**: filtros polinómicos de orden K

3 explicadores XAI (post-hoc)

- **GNNExplainer**: máscara por instancia
- **PGExplainer**: red generativa entrenada
- **GNNShap**: valores de Shapley por muestreo

Tres propiedades que no son lo mismo

Estabilidad

¿La explicación se reproduce entre semillas y perturbaciones?

Plausibilidad

¿Señala el patrón real de lavado (*ground-truth*)?


Fidelidad

¿Refleja de verdad la decisión interna del modelo?

Tesis central: *las tres son empíricamente independientes.*

Metodología

Qué produce, en concreto, un explicador



● nodo a explicar — aristas relevantes

Figura 2. Esquema de una explicación: nodo objetivo, aristas relevantes y ranking de *features*.

Fuente: elaboración propia.

Ante una transacción marcada como ilícita, el explicador devuelve dos cosas:

1. Una **máscara de aristas**: qué conexiones del vecindario sostienen la predicción.
2. Un **ranking de *features***: qué atributos del nodo pesaron más, de los 166 disponibles.

Las tres preguntas

Estabilidad: ¿sale lo mismo al repetir?

Plausibilidad: ¿coincide con el patrón real?

Fidelidad: ¿es lo que el modelo usó?

En Elliptic el vecindario tiene una mediana de ~ 2 nodos: ahí solo el ranking de *features* discrimina.

Metodología: un diseño de dos ejes

Eje 1 · Elliptic (real)

- Validez **externa**: transacciones reales.
- Sin *ground-truth*: solo estabilidad.
- Campo receptivo minúsculo (~ 2 nodos).

Eje 2 · Sintético (propio)

- Validez **interna**: *ground-truth* por nodo y arista.
- Permite medir plausibilidad y fidelidad.
- 4 tipologías estándar; 3 realizaciones.

Diseño factorial

4 arquitecturas × 3 explicadores × 3 balanceos × 5 escenarios

= 60 configuraciones por eje × 3 explicadores para el estudio de estabilidad

Protocolo de robustez

Estabilidad: 5 réplicas estocásticas por explicación. Inferencia (eje sintético): 3 semillas de modelo × 3 grafos, con Kruskal-Wallis, Wilcoxon e IC *bootstrap*.

Eje 1: Elliptic Bitcoin Dataset

- 203.769 nodos · 234.355 aristas · 166 features · 49 pasos.
- Ilícitas $\sim 2,2\%$ (razón $\sim 1:9$ en el subconjunto etiquetado).
- Split temporal causal (train 1–34 / val 35–42 / test 43–49).
- Campo receptivo mediana ~ 2 nodos: solo el Spearman discrimina.

Dataset: Weber et al. (2019).




Figura 3. Dispersión de la topología de Elliptic (grado y campo receptivo). *Fuente: elaboración propia.*

Eje 2: grafo sintético con ground-truth

- ¿Por qué? medir plausibilidad exige saber cuál subgrafo es el patrón: Elliptic no lo da.
- 4 tipologías: *structuring*, *layering*, *fan-in*, *fan-out*.
- Aristas distractoras + firma atenuada: la métrica discrimina.
- *Ground-truth* ciego al explicador; 3 realizaciones.




Figura 4. Grafo sintético con tipologías de lavado y *ground-truth* por arista. Fuente: elaboración propia.

Cómo se construyó el grafo sintético

Decisiones que endurecen la prueba

- **Simetrización** de aristas: sin ella el campo receptivo cae a ~ 2 nodos y la plausibilidad de subgrafo no es medible.
- **Aristas distractoras** ($n = 3$ por nodo de patrón): sin ellas cualquier *top-k* acertaría.
- **Firma de *features* atenuada** de +4 a +1,5: evita que la tarea se resuelva sola.

El *ground-truth* se fija en la construcción, **antes** de correr ningún explicador.

Escala y replicación

- ≈ 9.500 nodos, ≈ 1.530 ilícitos, ≈ 31.000 aristas.
- 4 tipologías canónicas plantadas dentro.
- Grafo g0: factorial completo $\times$ 3 semillas (540 filas).
- Grafos g1 y g2: corte de verificación (144 filas).

El contraste principal se calcula sobre la unión de los tres grafos.

Métricas y protocolo estadístico

- **Estabilidad**: correlación de Spearman entre rankings de features (primaria).
- **Plausibilidad**: coincidencia con el *ground-truth* de la tipología.
- **Fidelidad**: caída de la predicción al retirar lo importante (Fidelity+).
- **Rendimiento**: PR-AUC como métrica primaria (el F1 en umbral es degenerado bajo desbalance).

Estadística: Kruskal-Wallis, Wilcoxon e intervalos de confianza *bootstrap* (pruebas no paramétricas: no asumen normalidad).

Resultados

Contribución: dos artefactos de evaluación

1 · Fallo de memoria silencioso

Cálculo sobre el grafo completo: 13 configuraciones de GAT fallaban en silencio. *Favorecía a GAT.*

2 · Truncamiento del Spearman

La métrica descartaba features fuera del umbral: rankings mutilados. *Favorecía a GraphSAGE.*

Cada uno bastaba para una conclusión comparativa falsa. La estabilidad depende del protocolo de medición.

Además: dos *bugs* reportables en el PGExplainer de PyG 2.7.

En línea con la advertencia de Kosan et al. (2023) sobre la sensibilidad al protocolo.

El segundo artefacto: el truncamiento de la métrica

La métrica dimensionaba el vector de rangos por `top_k` en vez de por el número real de *features*.

Con `top_k= 20` sobre **166 features**, toda *feature* con índice ≥ 20 se descartaba: sobrevivían 2 o 3 y el resto quedaba empatado en cero.

El truncamiento **no penaliza por igual**: castiga más a las arquitecturas cuya importancia se reparte sobre muchas *features*.

Por eso deprimía a GAT (+0,24 al corregir) y a TAGCN (+0,28) mucho más que a GraphSAGE (+0,10), y fabricaba un liderazgo falso.

Los dos artefactos, juntos

1. **Memoria**: 13 configs de GAT fallaban por OOM silencioso; su media se calculaba solo sobre las que terminaban. *Favorecía a GAT.*

2. **Métrica**: el truncamiento anterior. *Favorecía a GraphSAGE.*

Cada uno **por separado** bastaba para una conclusión falsa.

Resultado 1: la estabilidad separa dos grupos, no cuatro puestos

■ GAT $0,782 \pm 0,013$

■ GCN $0,758 \pm 0,025$

brecha significativa entre grupos

■ GraphSAGE $0,735 \pm 0,022$

■ TAGCN $0,672 \pm 0,077$

Media de **3 semillas** (180 modelos); el $\pm$ es la **desviación típica entre semillas**, no el intervalo de confianza de la figura. Significativo **entre** grupos, **no dentro**: Wilcoxon pareado GAT vs GCN $p = 0,17$; GraphSAGE vs TAGCN $p = 0,10$.




Figura 5. Estabilidad (Spearman de GNNExplainer) por arquitectura en Elliptic; 3 semillas, 180 modelos, IC 95 %. *Fuente: elaboración propia.*

Robustez: qué sostiene esa partición

Tabla 1. Contrastes no paramétricos de la partición (Elliptic, 180 modelos).

Contraste	Estadístico	p
Global (4 arq.)	Kruskal-Wallis	$2,8 \times 10^{-5}$
Grupo alto vs bajo	Mann-Whitney	$1,4 \times 10^{-6}$
Dentro grupo alto	Kruskal-Wallis	0,19
Dentro grupo bajo	Kruskal-Wallis	0,08

- Tamaño de efecto $\eta^2 = 0,13$ (grande), el mismo estadístico que reporta la tesis en el eje sintético.
- IC95 % bootstrap: se solapan **dentro**, apenas se tocan **entre** grupos.
- Sobrevive la corrección de **Holm** por comparaciones múltiples.
- Los contrastes *dentro* de grupo son no pareados; los estadísticos son $(0,17, 0,10)$ y $(0,17, 0,10)$ respectivamente.

Reproducibilidad precisa

Reentrenamos la matriz completa. Los **pesos no** se reproducen bit a bit (*scatter* atómicos en GPU).

Las **conclusiones sí**: 25/60 sobre el filtro de calidad frente a 23/60, y la **misma partición**.

Distinguir ambas es, en sí mismo, una contribución metodológica.

Resultado 1b: concordancia entre regímenes

- La *inversión por densidad* era un **artefacto** de la métrica.
- Corregida, Elliptic (disperso) **concuerta** con el sintético (denso).
- El eje sintético separa **los mismos dos grupos**, sobre datos y *pipeline* independientes.

Correlación de rangos entre regímenes

−0,20 → +0,80

métrica con bug → métrica corregida

Sintético: GCN 0,97 y GAT 0,96 vs GraphSAGE
0,89 y TAGCN 0,89




Figura 6. Orden de estabilidad: Elliptic (disperso) frente al sintético (denso). *Fuente: elaboración propia.*

Resultado 2: disociación plausibilidad / fidelidad

- Por un lado, **PGExplainer** domina la plausibilidad: 0,80 vs 0,50, con 0,40 de azar (Wilcoxon $p \approx 2,6 \times 10^{-35}$).
- Por otro, **colapsa en fidelidad**: 0,11 vs 0,56 de GNNExplainer.
- *El explicador más “plausible” no es el más fiel.*

La figura compara los dos explicadores que producen máscara de aristas. GNNShap no la produce por diseño: su plausibilidad es de *features*, con otra escala y otra línea base, y va en la lámina de respaldo.




Figura 7. Plausibilidad de aristas frente a Fidelity+ (eje sintético; IC 95 %; azar de plausibilidad de aristas = 0,40). Fuente: elaboración propia.

Resultado 3: el puente que no existe

- Nuestra hipótesis central: una explicación más estable señalaría mejor el patrón real.
- El dato dice que **no**. Correlación estabilidad–plausibilidad $r = -0,01$, IC 95 % de $-0,038$ a $+0,011$.
- El intervalo **incluye el cero**: no hay relación.

Es un no-resultado, y lo reportamos precisamente porque contradice lo que esperábamos.




Figura 8. Relación estabilidad–plausibilidad (GNNExplainer): $r = -0,01$, IC incluye 0. *Fuente: elaboración propia.*

Resultado 4: el desbalance no gobierna la estabilidad

- Esperábamos degradación al agravarse el desbalance. **No la hay.**
- Rango estrecho: de 0,696 (1:1) a 0,765 (1:50), amplitud de **siete centésimas**, menor que las once que separan a las arquitecturas.
- **Kruskal-Wallis** $p = 0,18$: no se rechaza la igualdad entre los cinco escenarios. Tamaño de efecto $\eta^2 = 0,05$, pequeño frente al 0,13 de la arquitectura.
- El valor **más bajo** es 1:1, el más equilibrado: la variación no tiene dirección.
- El **balanceo** tampoco pesa: $\eta^2 \leq 0,01$ en las tres dimensiones.




Figura 9. Estabilidad media por escenario de desbalance sobre Elliptic, promediada sobre las 3 semillas de modelo. *Fuente: elaboración propia.*

Rendimiento y colapso validación → test




Figura 10. Rendimiento en validación y test sobre los mismos modelos: PR-AUC y precisión@50 colapsan, mientras que el ROC-AUC cae mucho menos y aparenta un modelo aceptable.

Fuente: elaboración propia.

- El modelo **aprende en validación** y **colapsa en test**: es el *shift* temporal del dataset (los patrones de lavado cambian con el tiempo). Propiedad del dato, no del método.
- El **ROC-AUC engaña** bajo desbalance (0,88): tomamos **PR-AUC** y **precisión@k** como primarias.
- La estabilidad se estudia sobre **verdaderos positivos de validación** (encuadre declarado).

Rigor métrico: por qué PR-AUC y no ROC-AUC

Tabla 2. Métricas de ordenamiento en validación y test (mismos modelos).

Métrica de ordenamiento	Validación	Test
ROC-AUC	0,884	0,653
PR-AUC	0,367	0,017
Precisión en los primeros 50	0,657	0,020
Precisión en los primeros 100	0,640	0,022

El ROC-AUC de 0,884 sugeriría un clasificador casi excelente. El PR-AUC de 0,367 sobre los mismos modelos revela la dificultad real: bajo desbalance extremo, el eje de falsos positivos queda dominado por la clase mayoritaria y permanece bajo aunque el modelo no distinga la clase rara.

Las tres hipótesis, y qué pasó con cada una

Tabla 3. Hipótesis de trabajo y su veredicto empírico.

Lo que predijimos	Veredicto	La evidencia
H1. La estabilidad se degradaría con el desbalance.	Refutada	Variación sin dirección: $p = 0,18$, mínimo en 1:1 (el más equilibrado).
H2. TAGCN sería la más estable (alcance multi-hop).	Refutada	TAGCN en el grupo bajo en las 3 semillas.
H3. Un explicador más estable señalaría mejor el patrón.	Refutada	Puente nulo: $r = -0,01$, IC incluye el cero.

Las tres se cayeron. **Ninguna se ocultó.** Comprometerse con predicciones falsables antes de ver los datos es lo que permite que refutarlas sea un resultado, y no un fracaso.

Conclusiones

Conclusiones del proyecto

1. **Tres dimensiones independientes** (estabilidad, plausibilidad, fidelidad): no existe una única “buena explicación”; el mejor explicador depende del objetivo de la auditoría.
2. **La estabilidad por arquitectura son dos grupos** (alto: GAT/GCN; bajo: GraphSAGE/TAGCN), y la partición **concuerta** entre datos reales y sintéticos.
3. **El explicador es la palanca dominante** (η^2 de 0,36 a 0,64); el balanceo es despreciable ($\eta^2 \leq 0,01$) y el escenario de desbalance, pequeño y no significativo ($\eta^2 \leq 0,05$).
4. **El más plausible no es el más fiel** (PGExplainer vs GNNExplainer): elegir según se quiera *reconocer el patrón* o *auditar el modelo*.
5. **Aporte metodológico**: dos artefactos de medición corregidos + distinguir reproducibilidad de *pesos* vs de *conclusiones*.
6. **Las tres hipótesis se refutaron con honestidad**: no debilitó la tesis, la fortaleció.

Los cuatro objetivos, respondidos

Tabla 4. Respuesta a los objetivos de investigación.

Objetivo	Respuesta
O1. Desbalance vs robustez explicativa	No es el factor dominante. Variación sin dirección entre escenarios ($p = 0,18$) y balanceo despreciable. La palanca real es el explicador .
O2. Resiliencia de las 4 arquitecturas	No hay cuatro posiciones, hay dos grupos . Se replica en ambos regímenes de densidad.
O3. Estrategias de balanceo	Despreciable en las tres dimensiones ($\eta^2 \leq 0,01$). Elegible por rendimiento.
O4. Matriz de recomendación	No existe tríada óptima única. Recomendación condicional al propósito .

Matriz de recomendación

Tabla 5. Matriz de recomendación por objetivo de auditoría.

Objetivo operativo	Configuración
Auditabilidad / estabilidad	grupo alto: GAT o GCN
Recuperar el patrón (plausibilidad)	PGExplainer
Fidelidad al modelo	GNNExplainer
Estabilidad interna del método	GNNShap

La recomendación de arquitectura es **de grupo**, no de una arquitectura concreta: dentro del grupo alto la evidencia no distingue, así que puede atender a coste o disponibilidad.

Contribuciones y limitaciones

Contribuciones

- Tres dimensiones independientes.
- Dos artefactos + dos *bugs* de PGExplainer.
- Generador sintético con *ground-truth* por arista.
- Reproducibilidad de **pesos** vs de **conclusiones**.
- Matriz de recomendación por objetivo.

Limitaciones (declaradas)

- La inferencia fuerte proviene del eje sintético.
- El clasificador colapsa en test (*shift* temporal).
- Un solo *dataset* real, anonimizado.
- Con 3 semillas se sostiene el **grupo**, no el orden fino dentro.

Gracias · Preguntas

Alejandro Gómez Huertas · Juan Diego Garzón Ovalle

Referencias seleccionadas i

- Weber, M. et al. (2019). *Anti-Money Laundering in Bitcoin: Experimenting with GCN for Financial Forensics*. KDD Workshop. arXiv:1908.02591.
- Kipf, T. & Welling, M. (2017). *Semi-Supervised Classification with Graph Convolutional Networks*. ICLR.
- Hamilton, W., Ying, R. & Leskovec, J. (2017). *Inductive Representation Learning on Large Graphs (GraphSAGE)*. NeurIPS.
- Veličković, P. et al. (2018). *Graph Attention Networks (GAT)*. ICLR.
- Du, J. et al. (2017). *Topology Adaptive Graph Convolutional Networks (TAGCN)*. arXiv:1710.10370.
- Ying, R. et al. (2019). *GNNExplainer: Generating Explanations for Graph Neural Networks*. NeurIPS.
- Luo, D. et al. (2020). *Parameterized Explainer for Graph Neural Network (PGExplainer)*. NeurIPS.
- Akkas, S. & Azad, A. (2024). *GNNShap: Scalable and Accurate GNN Explanation using Shapley Values*. WWW.
- Lundberg, S. & Lee, S. (2017). *A Unified Approach to Interpreting Model Predictions (SHAP)*. NeurIPS.
- Kosan, M. et al. (2023). *GNNX-BENCH: Benchmarking and Sensitivity of GNN Explainers*.
- Agarwal, C. et al. (2022). *Probing GNN Explainers: Fidelity vs. Plausibility*.

Referencias seleccionadas ii

- Lawal, O., Okolie, A. & Obunadike, C. (2025). *An Explainable GNN Framework for AML on the Elliptic Dataset*. IJNSA 17(5/6). DOI:10.5121/ijnsa.2025.17602.
- He, X. et al. (2026). *An Explainable GNN Framework for Illicit Financial Transaction Detection*. Applied Intelligence 56. DOI:10.1007/s10489-026-07138-9.
- Zhao, T., Zhang, X. & Wang, S. (2021). *GraphSMOTE: Imbalanced Node Classification on Graphs*. WSDM.
- Lin, T. et al. (2017). *Focal Loss for Dense Object Detection*. ICCV.

Respaldo · disociación: valores exactos

Tabla 6. Plausibilidad y Fidelity+ por explicador (eje sintético, g0, 3 semillas). Cada explicador se compara contra la línea base de azar de su propia métrica.

Explicador	Plaus. aristas	Plaus. features	Fidelity+
GNNExplainer	0,50	0,45	0,56
PGExplainer	0,80	n/d	0,11
GNNShap	n/d	0,15	0,46
<i>Azar (línea base)</i>	<i>0,40</i>	<i>0,08</i>	—

Las celdas n/d corresponden a métricas que el explicador no produce por diseño: PGExplainer no ordena *features* y GNNShap no genera máscara de aristas. Contra su propia línea base, PGExplainer duplica el azar en aristas y GNNExplainer lo sextuplica en *features*. PGExplainer supera a GNNExplainer en plausibilidad de aristas: Wilcoxon pareado $p \approx 2,6 \times 10^{-35}$ ($n = 225$ parejas). **GNNShap** es el más

Respaldo · estabilidad por semilla de modelo

Tabla 7. Estabilidad por semilla de modelo (Elliptic, GNNExplainer).

Arquitectura	s42	s43	s44	Media	IC95 %
GAT	0,766	0,789	0,790	0,782	[0,758; 0,805]
GCN	0,783	0,733	0,757	0,758	[0,724; 0,787]
GraphSAGE	0,756	0,713	0,738	0,735	[0,710; 0,756]
TAGCN	0,586	0,693	0,736	0,672	[0,632; 0,717]

GAT y **GCN** se permutan entre semillas: por eso no nombramos un ganador único. **TAGCN** tiene la mayor dispersión (dt 0,077, el triple): su lugar en el grupo bajo es firme, su valor central admite margen.

Respaldo · detalle estadístico de la partición

Tabla 8. Wilcoxon pareado por pares de arquitecturas (Elíptico y Sintético).

Wilcoxon pareado	Elíptico	Sintético
GAT vs GCN (<i>grupo alto</i>)	0,165	0,0013
GraphSAGE vs TAGCN (<i>grupo bajo</i>)	0,096	0,519
GAT vs GraphSAGE	0,0033	$< 10^{-4}$
GAT vs TAGCN	$< 10^{-4}$	$< 10^{-4}$
GCN vs GraphSAGE	0,047	$< 10^{-4}$
GCN vs TAGCN	0,0067	$< 10^{-4}$

La única diferencia intragrupo significativa es GCN sobre GAT en el sintético, por un margen de **0,006** sin relevancia práctica, detectable solo por el mayor n de ese eje.

Respaldo · ¿por qué GNNExplainer para el ranking?

Tabla 9. Estabilidad (Spearman) por explicador y arquitectura en Elliptic.

Explicador (Elliptic)	GAT	GCN	GraphSAGE	TAGCN
GNNExplainer	0,78	0,76	0,74	0,67
PGExplainer	0,00	0,00	0,00	0,00
GNNShap	0,97*	0,97	0,95	0,97*

GNNExplainer es el único que discrimina entre arquitecturas: PGExplainer degenera (Spearman nulo) y GNNShap se satura cerca de 0,96, indistinguible. Además es el explicador común a los dos ejes, lo que hace comparable la partición. GNNExplainer, a 3 semillas en las cuatro arquitecturas. GNNShap, a 3 semillas en GCN y GraphSAGE. Las marcadas con *, GAT y TAGCN, solo en la semilla 42.

Respaldo · curvas ROC y precisión-recall

El ROC-AUC engaña bajo desbalance: la curva PR revela la dificultad real




Figura 11. Curvas ROC (izquierda) y de precisión y exhaustividad (derecha) sobre validación y test, mismos