

Estabilidad de Métodos de Explicabilidad (XAI) en GNNs

Detección de Lavado de Dinero bajo Desbalance Extremo

Alejandro Gómez Huertas Juan Diego Garzón Ovalle

Trabajo de grado para optar al título de Magíster · Pereira, Colombia · 2026

UNIVERSIDAD TECNOLÓGICA DE PEREIRA

Facultad de Ingenierías · Maestría en Ingeniería en Sistemas y Computación

Director: Ph.D. Cristian Rosero Arias

Contenido de la sustentación

- 1 Problema y marco conceptual
- 2 Metodología: dos ejes
- 3 Resultados
- 4 Conclusiones

Formato

Defensa formal de 20 minutos. El detalle numérico queda en el respaldo, para las preguntas del jurado.

Problema y marco conceptual

El lavado es un patrón de red, y la GNN es una caja negra

- El lavado mueve 2 a 5 % del PIB mundial y se delata por el **patrón de conexiones**, no por transacciones aisladas.
- Las reglas fijas dan 95 a 98 % de falsos positivos. Las **GNN** modelan la red y superan a lo tabular, pero son **cajas negras**.
- En un entorno regulado el analista debe **justificar** cada alerta, y de forma **reproducible**.

Si la explicación **cambia** al recalcular, no sirve para auditar. Por eso la **estabilidad** es la propiedad crítica de esta tesis.




Figura 1. De un patrón de conexiones a una alerta sin explicación auditable. *Fuente: elaboración propia.*

Pregunta, objetivos e hipótesis

Pregunta de investigación

¿Cómo se comporta la **estabilidad** de los métodos XAI sobre GNNs para detección de lavado bajo desbalance, y qué combinación de **arquitectura**, **explicador** y **balanceo** produce la interpretación más robusta y auditable?

Objetivos

- O1 ¿Se degrada la estabilidad al agravarse el desbalance?
- O2 ¿Qué tan resilientes son las 4 arquitecturas?
- O3 ¿Influyen las estrategias de balanceo?
- O4 Condensar todo en una matriz de recomendación.

Hipótesis, escritas antes de ver los datos

- H1 La estabilidad se degradará con el desbalance.
- H2 TAGCN será la más estable, por su alcance multi-salto.
- H3 Un explicador más estable señalará mejor el patrón real.

Comprometerse con predicciones concretas antes de ver los datos es lo que hace que refutarlas signifique algo.

Qué es explicar una GNN

Una GNN actualiza cada nodo **agregando a sus vecinos**, capa por capa. La predicción depende del **vecindario**, no solo del nodo.

Cuatro arquitecturas por su forma de agregar: GCN promedia, GraphSAGE muestrea, GAT usa atención, TAGCN alcanza varios saltos.

Tres explicadores post-hoc sobre el modelo ya entrenado: GNNExplainer, PGExplainer y GNNShap.




Figura 2. Del paso de mensajes a las dos salidas del explicador.

Fuente: elaboración propia.

Explicar es señalar **qué aristas** y **qué features** sostuvieron la predicción.

Tres propiedades que no son lo mismo

Estabilidad

¿La explicación se reproduce entre semillas y perturbaciones?

Plausibilidad

¿Señala el patrón real de lavado (*ground-truth*)?

Fidelidad

¿Refleja de verdad la decisión interna del modelo?

Tesis central: *las tres son empíricamente independientes.*

Un explicador puede ser **estable y equivocado**, como un reloj parado: siempre marca lo mismo, y siempre mal.



Metodología

Un diseño de dos ejes

Eje 1 · Elliptic (real)

- Validez **externa**: transacciones reales de Bitcoin.
- Sin *ground-truth* de tipología: solo permite medir **estabilidad**.
- 203.769 nodos, 166 features, partición temporal causal.
- Campo receptivo minúsculo (~ 2 nodos): solo el ranking de features discrimina.

Eje 2 · Sintético (propio)

- Validez **interna**: *ground-truth* por nodo y arista.
- Permite medir además **plausibilidad** y **fidelidad**.
- 4 tipologías canónicas plantadas, con aristas distractoras y firma atenuada.
- 3 realizaciones del grafo para verificar.

La validez externa la da Elliptic. La inferencia fuerte sobre plausibilidad y fidelidad la da el sintético, porque Elliptic no dice cuál subgrafo es el patrón.

Diseño factorial, métricas y protocolo

4 arquitecturas × 3 explicadores × 3 balanceos × 5 escenarios

= 60 configuraciones por eje, cada una replicada con 3 semillas de modelo

Métricas

- **Estabilidad:** Spearman entre rankings de features.
- **Plausibilidad:** coincidencia con el *ground-truth*.
- **Fidelidad:** caída de la predicción al retirar lo importante (Fidelity+).
- **Rendimiento:** PR-AUC, no F1 ni ROC-AUC.

Protocolo estadístico

- Pruebas no paramétricas: Kruskal-Wallis y Wilcoxon.
- Intervalos de confianza *bootstrap*.
- Tamaño de efecto η^2 de ANOVA.
- Corrección de Holm por comparaciones múltiples.

Resultados

Contribución central: dos artefactos de medición

1 · Fallo de memoria silencioso

El cálculo sobre el grafo completo dejaba **13 configuraciones de GAT** en OOM silencioso, y su media salía solo de las que terminaban. *Favorecía a GAT.*

2 · Truncamiento del Spearman

La métrica dimensionaba los rangos por top_k y descartaba las features fuera del umbral, mutilando el ranking. *Favorecía a GraphSAGE.*

Cada artefacto, por separado, bastaba para una conclusión comparativa falsa.

La estabilidad medida depende del protocolo, no solo del método.

Además, dos *bugs* reportables en el PGExplainer de PyG 2.7. En línea con Kosan et al. (2023).

Resultado 1: la estabilidad separa dos grupos, no cuatro puestos

La corrección de la métrica, con la matriz reentrenada a **3 semillas (180 modelos)**, no revela un ranking de cuatro, sino una **partición en dos grupos**.

La línea **no** se traza por la distancia entre barras, sino por dónde la diferencia es **consistente**:

- **Entre** grupos: significativa.
- **Dentro** de cada grupo: no (Wilcoxon pareado $p = 0,17$ y $p = 0,10$).

GAT y GCN se permutan entre semillas: no hay un ganador único.




Figura 3. Estabilidad por arquitectura con IC 95 %. Los grupos se solapan por dentro y se separan en la brecha. TAGCN tiene la mayor dispersión. *Fuente: elaboración propia.*

Resultado 1b: la partición concuerda en ambos regímenes

- La *inversión por densidad* que reportaba una versión anterior era un **artefacto** de la métrica.
- Corregida, Elliptic (disperso) **concuerda** con el sintético (denso), sobre datos y *pipeline* independientes.
- El sintético separa **los mismos dos grupos**.

Correlación de rangos entre regímenes

$-0,20 \rightarrow +0,80$

métrica con *bug* a métrica corregida




Figura 4. Orden de estabilidad: Elliptic (disperso) frente al sintético (denso). Fuente: elaboración propia.

Resultado 2: el más plausible no es el más fiel

- **PGExplainer** domina la plausibilidad de aristas: 0,80 frente a 0,50, con 0,40 de azar (Wilcoxon $p \approx 2,6 \times 10^{-35}$).
- Pero **colapsa en fidelidad**: 0,11 frente a 0,56 de GNNExplainer.
- *El explicador más plausible no es el más fiel.* Confirma la independencia de las dimensiones.

La figura compara los dos explicadores con máscara de aristas. GNNShap no la produce por diseño: su plausibilidad es de features, con otra línea base, y va en el respaldo.




Figura 5. Plausibilidad de aristas frente a Fidelity+ (eje sintético, IC 95 %, azar de aristas = 0,40).

Fuente: elaboración propia.

Resultado 3: el puente que no existe

- Nuestra hipótesis central (H3): una explicación más estable señalaría mejor el patrón real.
- El dato dice que **no**. Correlación entre estabilidad y plausibilidad $r = -0,01$, con IC 95 % de $-0,038$ a $+0,011$.
- El intervalo **incluye el cero**: no hay relación.

Es un resultado nulo, y lo reportamos porque contradice lo que esperábamos.




Figura 6. Relación entre estabilidad y plausibilidad (GNNExplainer): $r = -0,01$, IC incluye 0. *Fuente: elaboración propia.*

Resultado 4: el desbalance no gobierna la estabilidad

Esperábamos (H1) que la estabilidad **cayera** al agravarse el desbalance. La curva observada es **plana y sin dirección**.

- Rango de 0,696 (1:1) a 0,765 (1:50), **siete centésimas**, menor que las once entre arquitecturas.
- **Kruskal-Wallis** $p = 0,18$: no se rechaza la igualdad. Efecto $\eta^2 = 0,05$ (pequeño).
- El mínimo está en **1:1**, el más equilibrado. La variación no tiene dirección.




Figura 7. Estabilidad por escenario: la predicción de H1 frente a la curva observada, plana. *Fuente: elaboración propia.*

Implicación: el balanceo puede elegirse por **rendimiento**, sin temer que degrade la interpretabilidad.

Rendimiento: colapso validación a test, por eso PR-AUC




Figura 8. PR-AUC y precisión@50 colapsan de validación a test, mientras el ROC-AUC cae mucho menos y aparenta un modelo aceptable. *Fuente: elaboración propia.*

- El modelo aprende en validación y **colapsa en test**: es el *shift* temporal del dataset, una propiedad del dato, no del método.
- El **ROC-AUC** engaña bajo desbalance (0,88). Tomamos **PR-AUC** y **precisión@k** como primarias.
- Por eso la estabilidad se estudia sobre los **verdaderos positivos de validación**, encuadre declarado en el manuscrito.

Conclusiones

Las tres hipótesis, y qué pasó con cada una

Tabla 1. Hipótesis de trabajo y su veredicto empírico.

Lo que predijimos	Veredicto	La evidencia
H1. La estabilidad se degradaría con el desbalance.	Refutada	Variación sin dirección: $p = 0,18$, mínimo en 1:1.
H2. TAGCN sería la más estable.	Refutada	TAGCN en el grupo bajo en las 3 semillas.
H3. Un explicador más estable señalaría mejor el patrón.	Refutada	Puente nulo: $r = -0,01$, IC incluye el cero.

Las tres se cayeron y las tres se reportan. Escribir las predicciones antes de ver los datos es lo que convierte su refutación en un resultado.

Conclusiones y matriz de recomendación

Conclusiones

1. **Tres dimensiones independientes:** no existe una única buena explicación.
2. **Dos grupos de estabilidad**, no cuatro puestos, y la partición concuerda entre datos reales y sintéticos.
3. **El explicador es la palanca dominante** (η^2 de 0,36 a 0,64). Balanceo despreciable ($\eta^2 \leq 0,01$), escenario pequeño y no significativo.
4. **El más plausible no es el más fiel.**
5. **Aporte metodológico:** dos artefactos corregidos y reproducibilidad de pesos frente a la de conclusiones.

Tabla 2. Recomendación por objetivo de auditoría.

Objetivo	Configuración
Auditabilidad	grupo alto: GAT o GCN
Recuperar patrón	PGExplainer
Fidelidad al modelo	GNNExplainer
Estabilidad interna	GNNShap

La recomendación de arquitectura es de **grupo**:

dentro del alto la evidencia no distingue, así que se elige por coste o disponibilidad.

Gracias · Preguntas

Alejandro Gómez Huertas · Juan Diego Garzón Ovalle

Referencias seleccionadas i

- Weber M y colaboradores (2019). *Anti-Money Laundering in Bitcoin: Experimenting with Graph Convolutional Networks for Financial Forensics*. arXiv:1908.02591.
- Kipf T y Welling M (2017). *Semi-Supervised Classification with Graph Convolutional Networks*. ICLR.
- Hamilton W, Ying R y Leskovec J (2017). *Inductive Representation Learning on Large Graphs*. NeurIPS.
- Veličković P y colaboradores (2018). *Graph Attention Networks*. ICLR.
- Du J y colaboradores (2017). *Topology Adaptive Graph Convolutional Networks*. arXiv:1710.10370.
- Ying R y colaboradores (2019). *GNNExplainer: Generating Explanations for Graph Neural Networks*. NeurIPS.
- Luo D y colaboradores (2020). *Parameterized Explainer for Graph Neural Network*. NeurIPS.
- Akkas S y Azad A (2024). *GNNShap: Scalable and Accurate GNN Explanation using Shapley Values*. WWW.
- Kosan M y colaboradores (2023). *GNNX-BENCH: Unravelling the Utility of Perturbation-based GNN Explainers through In-depth Benchmarking*. arXiv:2310.01794.
- Agarwal C, Zitnik M y Lakkaraju H (2022). *Probing GNN Explainers: A Rigorous Theoretical and Empirical Analysis of GNN Explanation Methods*. AISTATS.

Referencias seleccionadas ii

- He X y colaboradores (2026). *An Explainable Graph Neural Network Framework for Illicit Financial Transaction Detection*. Applied Intelligence 56.
- Zhao T, Zhang X y Wang S (2021). *GraphSMOTE: Imbalanced Node Classification on Graphs with Graph Neural Networks*. WSDM.

Respaldo · estabilidad por semilla de modelo

Tabla 3. Estabilidad por semilla de modelo (Elliptic, GNNExplainer).

Arquitectura	s42	s43	s44	Media	IC95 %
GAT	0,766	0,789	0,790	0,782	0,758 a 0,805
GCN	0,783	0,733	0,757	0,758	0,724 a 0,787
GraphSAGE	0,756	0,713	0,738	0,735	0,710 a 0,756
TAGCN	0,586	0,693	0,736	0,672	0,632 a 0,717

GAT y **GCN** se permutan entre semillas: por eso no nombramos un ganador único. **TAGCN** tiene la mayor dispersión (dt 0,077, el triple): su lugar en el grupo bajo es firme, su valor central admite margen.

Respaldo · disociación: valores exactos

Tabla 4. Plausibilidad y Fidelity+ por explicador (eje sintético, g0, 3 semillas). Cada explicador se compara contra la línea base de azar de su propia métrica.

Explicador	Plaus. aristas	Plaus. features	Fidelity+
GNNExplainer	0,50	0,45	0,56
PGExplainer	0,80	n/d	0,11
GNNShap	n/d	0,15	0,46
<i>Azar (línea base)</i>	<i>0,40</i>	<i>0,08</i>	no aplica

n/d = métricas que el explicador no produce por diseño. Contra su propia línea base, PGExplainer duplica el azar en aristas y GNNExplainer lo sextuplica en features. **GNNShap** es el más estable internamente (0,98).

Respaldo · ¿por qué GNNExplainer para el ranking?

Tabla 5. Estabilidad (Spearman) por explicador y arquitectura en Elliptic.

Explicador (Elliptic)	GAT	GCN	GraphSAGE	TAGCN
GNNExplainer	0,78	0,76	0,74	0,67
PGExplainer	0,00	0,00	0,00	0,00
GNNShap	0,97*	0,97	0,95	0,97*

GNNExplainer es el único que discrimina entre arquitecturas: PGExplainer degenera (Spearman nulo) y GNNShap se satura cerca de 0,96. Es además el explicador común a los dos ejes. GNNShap a 3 semillas cubre GCN y GraphSAGE. Las marcadas con *, GAT y TAGCN, solo en la semilla 42.

Respaldo · curvas ROC y precisión-recall




Figura 9. Curvas ROC (izquierda) y precisión-recall (derecha), validación frente a test, mismos modelos. El ROC cae de 0,88 a 0,65, pero la precisión-recall se desploma casi a la tasa base de ilícitas. *Fuente: elaboración propia.*